

Informe de Trabajo Práctico 3 - Métodos No Supervisados

Parte I: Limpieza y Creación de Variables

Se integraron dos bases de datos de encuestas del año 2004 y 2024. Para poder compararlas:

- Se homogeneizaron los nombres de las variables en mayúsculas.
- Se agregó una columna "AÑO" para identificar el origen temporal de cada observación.
- Se unificaron las bases con `pd.concat`, manteniendo solo columnas comunes.

Se construyó la variable EDAD2 como el cuadrado de la edad (CH06) y se unificó la variable ESTADO (ocupado/desocupado) para facilitar los análisis comparativos.

Se generaron histogramas y curvas de densidad para explorar la distribución de edad según el estado laboral, observándose una diferencia clara entre ocupados y desocupados.

La variable EDUC fue construida a partir de CH12, CH13 y CH14, codificando los niveles educativos en años equivalentes.

Se ajustó el ingreso semanal (SALARIO_SEMANAL) para homogeneizar los valores de 2004 y 2024 usando un IPC relativo (factor de 30). Luego se graficaron histogramas y densidades de salario.

Se definió HORASTRAB como la suma de horas trabajadas en la actividad principal y secundaria. Finalmente, se mostró una tabla resumen comparativa entre los años.

Parte II: Métodos No Supervisados


Se seleccionaron las variables cuantitativas más relevantes: edad, edad al cuadrado, educación, salario semanal y horas trabajadas. Se estandarizaron para posterior análisis.

- Se aplicó Análisis de Componentes Principales (PCA) para observar la estructura de los datos. Se mostraron los componentes principales, los "loadings" y la proporción de varianza explicada.
- Se ejecutaron modelos de K-means con diferentes valores de k (2, 4, 10), y se visualizaron los clusters en los dos primeros componentes principales. Además, se compararon los clusters con el estado ocupacional para ver si existía una relación clara.
- Para complementar, se implementó clustering jerárquico. Dado que los dendogramas con muchas observaciones no son informativos, se graficó el dendograma sobre una muestra aleatoria de 100 observaciones para mostrar la estructura jerárquica de agrupamiento.

Conclusión sacada a a partir del Trabajo Practico 3.


Los métodos no supervisados permitieron identificar patrones en los datos relacionados con edad, educación, salario y estado ocupacional. Las técnicas como PCA, K-means y clustering jerárquico aportan diferentes perspectivas sobre la segmentación de la población relevada.

GRAFICOS:



Edad²: En este histograma observamos la mayor concentración entre los 20 y los 40. Se obtuvo una tendencia a disminuir a medida que aumenta la edad. Podemos asumir que a partir de los 30 en adelante, las variables de edad y frecuencia presentan una relación inversa.

Panel B: Densidad de Edad por Estado



Distribución de Kernel apoya nuestra hipótesis planteada en el segundo informe de la presente materia. Hay una gran cantidad de PEA de 20 que no consigue trabajo y aquellos que sí, tienden a mantenerlo, como se aprecia en la distribución de ocupados entre los 20 y hasta los 60 que ya empiezan a gozar de sus haberes jubilatorios. La enorme caída en los desocupados dada entre los 25 y 30 puede ser justificable con la finalización de estudios terciarios y su inserción al mercado laboral como mano más calificada.


Educación

En educación, se analizó cuántos terminaron una educación formal completa (12 años finalizados en 2 niveles de educación):


count	60530.000000
mean	14.082372
std	9.612990
min	5.000000
25%	11.000000
50%	14.000000
75%	17.000000
max	116.000000

Estos resultados arrojan que la gran mayoría de los entrevistados tiene aprobado el 75% de la educación formal estándar. Hay una media del 14.08 de todos los entrevistados en general con estudios finalizados.

Salario:



Panel B: Densidad de Salario Semanal




En salarios (con ajuste por inflación) se aprecia un pico gigantesco en 50.000 pesos semanales (aproximación) lo cual lo ubicaría (en un periodo 2024) en la media del salario mínimo. Lo que deja concluir que la gran mayoría no tiene un trabajo donde se pague por encima del mínimo. Ya ajustado por inflación muestra que este salario es menor en términos adquisitivos al mínimo nominal establecido por ley.

En las estadísticas realizadas a las horas trabajadas se vio una gran desviación (36%), por ende, se puede considerar un posible sesgo muestral o una fuerte heterogeneidad respecto al promedio trabajado por los entrevistados.


Tabla 1. Resumen de la base final para la region YYY


	2004	2024	Total
Cantidad observaciones	45289	46050	91339
Cantidad de observaciones con Nas en la variable “Estado”	0	0	0
Cantidad de Ocupados	17022	20325	37347
Cantidad de Desocupados	2717	1362	4079
Cantidad de variables limpias y homogeneizadas	178	178	356

Aquí se aprecia el fenómeno de “salir a buscar trabajo”. Mucha población debido a la crisis económico fue a buscar trabajo, muchos de esos como subocupados sin intención de aumentar sus horas de trabajo.




Relación de crecimiento entre las horas trabajadas (reconocidas) y el salario con el estas se remunerarán, al igual que un leve aumento por nivel de educación superado con éxito. Al igual que por mayor edad, al reconocerse experiencia y antigüedad en puestos laborales.








Edad y salarios son las variables que más peso generan, como se ve en los gráficos. Educación en una menor proporción dada.




La varianza acumulada, la cual aumenta a mayor número de componentes, refuerza nuestro pensamiento de muestras muy heterogéneas en ambas bases. En nuestra opinión evidencian aumentos en la desigualdad.

En Clusters, se ve que el algoritmo presenta algunas dificultades para dividirlos en 2 k grupos, algo que se soluciona mediante el aumento de dicha variable. Aún conserva su forma curva, a pesar del incremento del algoritmo:





Distribución con K = 2



Cluster jerárquico

Dendograma: Un dendograma es un diagrama de árbol, su propósito es mostrar cada elemento individual y los clusters que hay comprendidos. En clusters jerárquicos muestra estos grupos a través de sus ramas, uniendo cada hoja (elementos individuales)

