

Informe: Estimación y Validación de Modelos de Regresión Lineal — TP4

En cumplimiento con los objetivos del Trabajo Práctico N°4, se procedió a implementar y evaluar una serie de modelos de regresión lineal sobre la base de datos de personas ocupadas extraída de la EPH para el año 2024, con foco en predecir la variable dependiente salario_semanal.

1. Estimación de modelos (Tabla 2)

Se estimaron cinco modelos de regresión lineal sobre la base de entrenamiento (70% de la muestra, random_state=444), incorporando progresivamente mayor complejidad en los predictores utilizados. Las variables fueron seleccionadas en función de su relevancia teórica y empírica según lo trabajado en los TP2 y TP3:

Modelo	Variables incluidas
Modelo 1	edad
Modelo 2	edad, edad ²
Modelo 3	edad, edad ² , educ
Modelo 4	edad, edad ² , educ, mujer (dummy: mujer=1 si CH04==2)
Modelo 5	edad, edad ² , educ, mujer, dummies de región

Los coeficientes fueron estimados con el método OLS utilizando statsmodels. Se reportan en la Tabla 2 los coeficientes con tres decimales y sus errores estándar entre paréntesis con dos decimales. Asimismo, se indican significancias estadísticas con asteriscos según los niveles estándar (0.1, 0.05 y 0.001).

Comentario sobre Tabla 2:

- La edad tiene un efecto positivo y significativo en todos los modelos, aunque decreciente cuando se incorpora el término cuadrático.
- La variable educ (nivel educativo) se asocia positivamente al salario, como era esperado.
- La dummy de mujer mostró un coeficiente negativo y significativo, reflejando una brecha salarial por género.

- La inclusión de variables regionales en el Modelo 5 incrementó el R^2 , sugiriendo una mejora explicativa al capturar diferencias territoriales.

2. Evaluación de desempeño en testeo (Tabla 3)


Utilizando las observaciones reservadas para testeo (30% de la muestra), se generaron predicciones de salario_semanal ($\hat{y}_{test}$) para cada modelo, aplicando los coeficientes estimados previamente. Se calcularon las siguientes métricas de evaluación para comparar el desempeño predictivo entre modelos: MSE (Error Cuadrático Medio), RMSE (Raíz del ECM), y MAE (Error Absoluto Medio).

Comentario sobre Tabla 3:

- A medida que se agregan variables explicativas, las métricas de error disminuyen de manera sostenida.
- El Modelo 5 presentó la menor MAE y RMSE, confirmando que incorporar dummies regionales ayuda a capturar heterogeneidad no explicada por edad, educación y género.
- Esta mejora, sin embargo, implica mayor complejidad en términos de implementación y mantenibilidad del modelo, por lo que su aplicación dependerá del contexto operativo en el que se requiera utilizarlo.

3. Regresión logística y KNN

En el análisis hecho con el método de regresión para determinar el año obtuvo una precisión del 87% frente al 84% del KNN. Por lo que sería el más acertado de los dos para tratar de predecir el año. Aunque el KNN con $K=5$ permitió detectar mejor los casos de desempleados, así que lo mejor sería tomar, si se quiere una exactitud de desempleados, este modelo por encima de la regresión. Sus porcentajes de AUC (area under the curve) apenas superan el 50% y son relativamente bajos en proporción a la precisión y superando el margen del azar, por lo que ambos son confiables, pero se recomienda análisis más profundos antes de cualquier decisión. A continuación se verá:



4. Consideraciones finales

Este análisis sugiere que:

- La regresión lineal es una herramienta útil para predecir ingresos semanales, siempre que se seleccionen predictores relevantes y se valide el modelo con datos fuera de muestra.
- Las variables sociodemográficas como edad, educación y género capturan bien la varianza del salario.
- La inclusión de variables regionales aporta valor predictivo adicional, aunque debe evaluarse su costo computacional frente a los beneficios de precisión.

Quedo a disposición para ampliar estos resultados o explorar alternativas de modelos más complejos si se considera oportuno.